

ניתוח רשתות חברתיות-דו"ח מסכם

מוטיבציה:

הרשת שאותה ניתחנו במהלך הסמסטר והפרויקט זוהי רשת הציטוטים CORA - רשת ציטוטים בין מאמרים הקשורים למדעי המחשב. כל קשת מייצגת ציטוט של מאמר אחד מתוך מאמר אחר (כלומר אם מאמר A מצטט את מאמר B נוצר חץ מ-A ל-B) כל מאמר מתואר על ידי ID, ונושא המאמר. מיפינו את 7 תחומי המאמרים לפי שלוש קטגוריות על AI, Theory, Systems בעזרת טבלת התאמה ע"י הבינה מלאכותית (המתוארת בקוד). כך יכולנו לנתח את הקשרים והמאפיינים של כל תחום בנפרד, גם מבחינת מבנה הרשת כאשר הצמתים נצבעו לפי הקבוצות: AI- אדום 1071 קודקודים, Theory- כחול 723 קודקודים System - ירוק 691 קודקודים.

מודל הנתונים ושאלת המחקר:

המחקר מבוסס על רשת הציטוטים CORA מתוך מאגר הנתונים [DATASET LINQS](#), רוב החישובים נעשו ע"י פונקציות בנויות בפייתון תוך שימוש בפונקציות מובנות של NetworkX קישור לגיט להורדת הפרויקט: [LINK GITHUB](#)

שאלת המחקר-

האם קיים קשר בין תחום המחקר של מאמר לבין המיקום והמעמד שהוא תופס ברשת הציטוטים האקדמית? כלומר האם מאמרים בתחומים שונים – כמו בינה מלאכותית AI, תחומים תיאורטיים Theory או תחומי מערכות Systems נוטים לתפוס תפקידים רשתיים שונים, כגון: צומת מרכזי, מקושר או מבודד? השערת המחקר- השערותנו היא כי תחום המחקר Systems יתפוס מעמד גבוה יותר ברשת – כלומר יהיה מקושר יותר, זאת מהסיבה שמאמרים בתחום זה עוסקים רבות ביישומים, בתשתיות מערכתיות ובקשרים בין רכיבים שונים. תחום המערכות מהווה לרוב בסיס לפיתוחים מחקריים בתחומים נוספים ולכן מצטט ומצוטט לעיתים תכופות ע"י תחומי מחקר אחרים. בנוסף, מערכות משולבות – כמו מערכות הפעלה, רשתות, או ארכיטקטורה חישובית – נמצאות במרכז הזרימה של ידע טכנולוגי, ולכן סביר שיתפסו תפקיד מרכזי ברשת הציטוטים.

פתרון שאלת המחקר וניתוח הנתונים-

תחילה כדי לבדוק ולהכיר את הרשת חקרנו נתונים מאוד בסיסיים:
- גודל הגרף: מכיל 2485 צמתים, 5209 קשתות.
- סוג הגרף: גרף מכוון [לחצו להצגת הגרף](#)
- מספר קשתות מכל סוג [לחצו להצגה](#)
- האם מולטיגרף? לא- כל זוג צמתים מחוברים בקשת אחת לכל כיוון
- קוטר הרכיב הקשיר הגדול: 19
- מספר לולאות עצמיות: 0 הגיוני ☺
- תכונת העולם הקטן:
הבדיקה התבססה על אורך המסלול הקצר ביותר ומקדם ההתקבצות. נדגמו 13 זוגות, עם אורך מסלול ממוצע של 4.6 ומקדם התקבצות של 0.238. המסקנה: הגרף שנבדק מקיים את תכונת העולם הקטן תכונה זו מצביעה על כך שהרשת כוללת צמתים צפופים בקהילות ובו בזמן יש מסלולים קצרים בין קבוצות שונות.

המשמעות היא שיש צמתים (כלומר מאמרים) שיכולים לשמש כצמתים מרכזיים ובולטים – תכונה זו תומכת ברעיון שתחומים כמו AI שמתאפיינים בציטוטים רבים ובקשרים בין תחומיים, צפויים לתפוס מעמד גבוה יותר ברשת.

-התפלגות דרגות:

בקטגוריית System: [IN](#) [OUT](#) [TOTAL](#)

בקטגוריית AI: [IN](#) [OUT](#) [TOTAL](#)

בקטגוריית Theory: [IN](#) [OUT](#) [TOTAL](#)

בבחינת התפלגויות הדרגות לפי קטגוריה, נמצא כי בקטגוריית Systems יש מספר מצומצם של צמתים עם דרגות גבוהות מאוד – תופעה שלא נצפתה באותה עוצמה בקטגוריות AI או Theory. ממצא זה תומך בהשערה כי תחום המערכות כולל מאמרים בעלי מעמד רשת מרכזי, המשפיעים על מבנה הרשת כולו – ומאשר כי למאמרים בתחום זה יש קישוריות גבוהה יותר בהשוואה לשאר התחומים.

-חוק חזקה Power law:

במסגרת הבדיקה שלנו, בחנו האם התפלגות הדרגות ברשת הציטוטים האקדמית תואמת לחוק החזקה (Power Law) עבור שלושת תחומי המחקר. התוצאות הראו כי בכל אחת מהקטגוריות מתקיים מבנה Scale-Free, כלומר – רוב הצמתים מקושרים למעט צמתים בלבד, בעוד שקיימים מספר קטן של צמתים מרכזיים מאוד, בעלי דרגה גבוהה במיוחד. בקטגוריית AI: התקבל ערך $\beta = 3.04$ עם $p\text{-value} = 0.8581$, המעיד על מבנה רשת חופשי-סולם עם מספר צמתים מקושרים מאוד, אך בצורה פחות קיצונית. [לצפייה בגרף](#) בקטגוריית Theory: התקבל ערך $\beta = 3.15$ עם $p\text{-value} = 0.6101$, מציג תבנית דומה אך פחות חדה, עם התפלגות יחסית שטוחה של הקישורים. [לצפייה בגרף](#) ואילו בקטגוריית System: התקבל ערך $\beta = 3.32$ עם $p\text{-value} = 0.8328$ – הגבוה ביותר מבין השלוש שמעיד על מבנה רשת ריכוזי במיוחד, שבו מספר קטן של צמתים מרכזיים מחזיקים את עיקר הקישורים. [לצפייה בגרף](#)

תוצאה זו גם מחזקת את השערת המחקר שלנו, לפיה תחום Systems מאופיין בצמתים בולטים ומרכזיים ברשת הציטוטים, תורמים רבות לקישוריות הכוללת של הרשת, ומשמשים כצמתי מעבר בין תחומים אחרים.

-מדדי מרכזיות:

כדי לנתח אילו מאמרים תופסים עמדות מרכזיות ברשת הציטוטים, חישבנו שלושה מדדי מרכזיות קלאסי Degree, Closeness ו-Betweenness. עבור כל מדד זיהינו את עשרת הצמתים המובילים, ולאחר מכן חישבנו לכל צומת מדד פופולריות, אשר מציין בכמה מהמדדים הופיע הצומת בין עשרת הראשונים. צמתים שקיבלו ציון פופולריות של 2 ומעלה נחשבים לבעלי מרכזיות עקבית ומשמעותית, ואלו נמצאו בעיקר בקטגוריית System באופן שמחזק את ההשערה שתחום זה תופס מעמד רשת גבוה מהאחרים. [לצפייה בקודקודים](#)

מניתוח כלל הצמתים המרכזיים, עלה כי ארבעה מתוכם שייכים ל- Systems לעומת שלושה בלבד ל- AI ושלושה ל- Theory הצומת הבולט במיוחד הוא צומת 35, השייך ל- System שמוביל הן במדד Degree והן במדד Closeness – בפער ניכר מהמוצא. ממצא זה מדגיש את תפקידם המרכזי של מאמרים בתחום Systems ברשת הציטוטים, הן מבחינת קישוריות והן מבחינת קרבה ותווך – ושוב מחזק את ההשערה כי מאמרים בתחום זה ממלאים תפקיד מרכזי בהפצת ידע ובהשפעה על תחומים נוספים.

הדבר תומך בתפיסה כי מערכות (System) מהוות תשתית ידע שחוצה תחומים, ולכן תופסות עמדות

רשתיות גבוהות יותר ממאמרים מתחומים אחרים.

Page Rank-

בנוסף למדדי המרכזיות הקלאסיים, חישובנו גם את מדד PageRank ע"י פונקציה מובנית בפייתון אשר בוחן את החשיבות של צומת לפי איכות המאמרים שמפנים אליו. מהטבלה עולה כי 5 מתוך 10 הצמתים המרכזיים ביותר לפי PageRank שייכים לתחום System יותר מכל תחום אחר. [לצפייה בטבלה](#)

זה מחזק את המסקנה כי תחום System תופס תפקיד מרכזי ומשפיע ברשת הציטוטים – לא רק בכמות הקישורים, אלא גם באיכותם.

- Independent Cascade (ICM) :

כדי להעמיק את ההבנה לגבי השפעת תחום המחקר על המעמד הדינמי של מאמרים ברשת הציטוטים, ביצענו סימולציה של הפצת מידע לפי מודל ה-ICM. מודל זה מדמה תהליך בו כל מאמר פעיל (כלומר: "מודע לרעיון") מנסה להפעיל את שכניו ברשת – כלומר "להעביר אליהם את ההשפעה" – בהסתברות קבועה מראש. במקרה שלנו, ההסתברות להפעלה בין צומת לשכנו הוגדרה כ- $p=0.3$, וכל צומת מקבל ניסיון יחיד בלבד להפעלת שכניו.

לצורך הבדיקה, נבחרו 5 צמתים מכל תחום מחקר – (AI, Theory, Systems) כך שכל תחום ייצג קבוצת התחלה (seed set) להפצה. הצמתים שנבחרו הם אלו בעלי דרגת היציאה (out-degree) הגבוהה ביותר באותו תחום, מתוך הנחה שהם בעלי פוטנציאל השפעה רחב יותר. הסימולציה בוצעה על הרשת וכל הפעלה נמשכה עד שלא נותרו צמתים חדשים שניתן להפעיל.

תוצאות הסימולציה היו:

Theory הפעיל 20 צמתים

AI הפעיל 17 צמתים

Systems הפעיל 15 צמתים [לצפייה בגרף התוצאות](#)

ממצאים אלה מצביעים על כך שתחום Theory הפגין את רמת ההשפעה הגבוהה ביותר בתנאים שנבדקו. ממצא זה עשוי לרמז כי למרות המרכזיות הסטטית של תחום Systems שנצפתה במדדים קודמים, תחום Theory ממלא תפקיד חשוב יותר בהפצת רעיונות ומידע ברשת הציטוטים, וייתכן שהוא מחבר בין קבוצות שונות בצורה אפקטיבית יותר. בכך, אנו מבחינים בהבדל משמעותי בין מרכזיות סטטית (למשל, לפי Degree) לבין השפעה דינמית בפועל – מה שמעשיר את התמונה הכוללת לגבי תפקוד תחומי המחקר ברשת האקדמית.

- Community Detection :

במטרה לבדוק את הקשר בין תחום המחקר של מאמר לבין המיקום והמעמד שלו ברשת הציטוטים, ביצענו ניתוח של קהילות באמצעות שני אלגוריתמים שונים Louvain ו-Propagation Label ניתוח הקהילות מאפשר לזהות קבוצות מאמרים שמקושרים זה לזה בצורה צפופה יותר – ולעיתים קרובות משקפות תחומי עניין משותפים. אם קיים קשר מובהק בין הקהילות שנוצרו לבין תחומי המחקר (AI, Theory, Systems), הדבר עשוי להעיד על כך שמבנה הרשת מושפע מהתחום עצמו – כלומר שמאמרים מאותו תחום נוטים להצטופף יחד ברשת.

השתמשנו בגרסה לא מכוונת של הרשת תוך שמירה על מבנה הקשרים, והפעלנו עליה את אלגוריתם Louvain אשר ממקסם את המודולריות של הקהילות. לאחר חלוקה ל-29 קהילות, חישובנו לכל קהילה את מספר הצמתים מכל תחום מחקר, וזיהינו את התחום הדומיננטי – זה שמופיע בהכי הרבה מאמרים. כמו כן חישובנו את אחוז השליטה – מהו אחוז הצמתים בקהילה השייכים לתחום הדומיננטי. בצורה זו, ניתן להבחין אילו תחומים נוטים להוביל קהילות, ואילו מופיעים במבנה מפוזר

יותר.

גרף העמודות ([click stacked bar](#)) מציג את הרכב כל אחת מהקהילות לפי תחומי המחקר. הגרף ממחיש האם הקהילות הומוגניות (נשלטות ע"י תחום אחד), או מעורבות. גרף העוגה ([click pie chart](#)) מסכם את הנתונים ומראה כמה קהילות נשלטות ע"י כל תחום. כך ניתן לזהות בקלות מגמות של שליטה רשתית. לדוגמה, אם רוב הקהילות נשלטות ע"י תחום ה-AI ניתן להסיק שמאמרים בתחום זה יוצרים רשתות פנימיות חזקות וצפופות.

ניתוח התפלגות הקהילות העלה כי תחום ה-AI שולט ברוב הקהילות (כ-45%), ואחריו Theory ו-Systems משמעות הדבר היא שמאמרים מתחום ה-AI נוטים להופיע יחד באותן קהילות – כלומר הם מצטטים ומצוטטים זה ע"י זה, ויוצרים מבנה צפוף. לעומת זאת, תחום Systems הופיע פחות כתחום שולט, מה שעשוי להעיד על מבנה רשת פחות צפוף או גישור בין תחומים. ממצאים אלו תומכים בהשערת המחקר שלנו: קיים קשר בין תחום המחקר של מאמר לבין המיקום והמעמד שלו ברשת – והתחום משפיע על הסיכוי של מאמר להיות מקושר או מרכזי. לצורך חיזוק המסקנות, הרצנו גם את אלגוריתם – Label Propagation שיטה חלופית מהירה הפועלת על בסיס הפצת תוויות בין שכנים. השוואה בין השיטות מראה הבדל משמעותי: בעוד Louvain חילק את הרשת ל-29 קהילות ברורות Label Propagation, זיהה 398 קהילות – רבות מהן קטנות מאוד (ואף בגודל 1-2). ממצא זה מצביע על כך ש-Louvain מספק חלוקה משמעותית יותר, המתאימה טוב יותר לתחומי המחקר. לכן, ההסקות שלנו מבוססות בעיקר על תוצאות Louvain.

סיכום ומסקנה:

לאורך התהליך חקרנו את רשת הציטוטים CORA ממגוון זוויות – מבניות, חישוביות ודינמיות – כדי לענות על שאלת המחקר שבמרכזה עומד הקשר בין תחום המאמר לבין תפקידו ברשת. ניתחנו את הרשת תחילה ברמה הגלובלית, שהראו כי תחום Systems כולל צמתים מרכזיים ובעלי קישוריות גבוהה. העמקנו את הניתוח בעזרת כלים סטטיסטיים כמו חוק החזקה, וזיהינו שמאמרים בתחום Systems נוטים להיות בעלי דרגות קצה גבוהות במיוחד – ממצא שתומך ברעיון של רשת ריכוזית. יחד עם זאת, סימולציית הפצת מידע לפי מודל ICM הראתה שדווקא תחום Theory משפיע יותר דינמית על הרשת, ותחום AI יוצר קהילות צפופות פנימיות, כפי שנחשף בניתוח הקהילות (Community Detection).

השילוב בין ניתוח מבני, סימולציות והשוואת תחומי מחקר סיפקו לנו הבנה עמוקה של הרשת. המסקנה הברורה היא שתחום המחקר של מאמר משפיע על מקומו ברשת, אך ההשפעה באה לידי ביטוי בדרכים שונות: מרכזיות, הפצה או השתייכות קהילתית – ולכל תחום יש דפוס ייחודי. בכך, הצלחנו לא רק לבדוק את השערת המחקר אלא גם ללמוד לעומק על המורכבות של ניתוח רשתות חברתיות.

כיווני מחקר עתידיים:

יש עוד הרבה לאן להמשיך מכאן לדוג', יהיה מעניין לבדוק איך רשת הציטוטים משתנה לאורך זמן – האם אותם תחומי מחקר נשארים במרכז, או שהמרכזיות ברשת משתנה עם השנים? כיוון נוסף הוא להשוות את רשת CORA לרשתות אחרות מתחומים שונים, כמו ביולוגיה, פיזיקה או מדעי החברה ולבדוק אם גם שם קיימת השפעה של תחום המאמר על המיקום שלו ברשת.